



OPEN 使用监督机器学习和可解释的人工智能来预测和理解熟练联合行动期间的人类行动决策

法布里齐亚·奥莱塔、雷切尔·W·卡伦、马里奥·迪·贝尔纳多和迈克尔·J·理查森

本研究调查了监督机器学习 (SML) 和可解释的人工智能 (AI) 技术在多智能体任务执行过程中建模和理解人类决策的效用。长短期记忆 (LSTM) 网络经过训练，可以预测完成多智能体放牧任务的专家和新手玩家的目标选择决策。结果表明，经过训练的 LSTM 模型不仅可以准确预测专家和新手玩家的目标选择决策，而且这些预测可以在玩家有意识意图之前的时间尺度上做出。重要的是，这些模型也是针对专业知识的，因为经过训练来预测专家的目标选择决策的模型无法准确预测新手的目标选择决策（反之亦然）。为了了解专家和新手目标选择决策的差异，我们采用了可解释的 AI 技术，即 SHapley 附加解释 (SHAP)，来确定哪些信息特征（变量）对模型预测影响最大。SHAP 分析显示，与新手相比，专家更依赖有关目标航向和协调员（即其他玩家）位置的信息。讨论了使用 SML 和可解释的人工智能技术来调查和理解人类决策的含义和假设。

与其他人一起执行任务是人类日常生活的重要组成部分。这种行为要求合作者相互协调他们的行动并改变任务需求。这种行动的结构组织的关键是合作者有效决定如何以及何时采取行动的能力，稳健的决策往往能够区分专家和非专家的表现。无论是家庭成员一起将洗碗机装进洗碗机的简单活动，还是精英运动员在团队运动中或士兵在高风险军事行动中进行的更复杂的活动，都是如此。

与实际推理或深思熟虑的决策相反，在实际推理或深思熟虑的决策中，行动者广泛评估所有可能性以确定最佳行动，而在熟练行动期间发生的决策通常是快节奏且高度依赖于上下文的，行动者会自发地调整他们的行动以适应实际情况。“尽可能最好”地实现任务目标。事实上，熟练行为期间行动决策的有效性是行动者情境意识水平的函数，任务专业知识反映了行动者对信息的协调，这些信息指定了哪些行动可能性（最佳或次优）确保任务完成。因此，对熟练行为过程中决策的全面理解取决于研究人员和实践者识别哪些任务信息是有效决策绩效的基础的能力。实现这一目标的关键是开发决策模型，该模型不仅可以预测人类参与者在熟练行动期间的行动决策，还有助于识别专家与非专家表现的区别。受这些挑战的推动，当前的研究提出使用最先进的监督机器学习（SML）和可解释的人工智能（AI）技术来建模、预测和解释行动

1 澳大利亚新南威尔士州悉尼麦考瑞大学医学、健康与人文科学学院心理科学学院。英国布里斯托尔大学工程数学系。澳大利亚新南威尔士州悉尼麦考瑞大学精英表现、专业知识和培训中心。那不勒斯大学电气工程与信息技术系，费德里科二世，那不勒斯，意大利。南方高等学校，那不勒斯，意大利。电子邮件：mario.dibernardo@unina.it；michael.j.richardson@mq.edu.au

执行快节奏联合行动任务的专家和新手的决策。具体来说，我们在文献中首次展示了如何使用这些计算技术来揭示共同行动者在联合行动（和个人）任务环境中做出行动决策时利用的关键信息。

监督机器学习。

机器学习 (ML) 技术的应用在过去十年中迅速增长。例如，机器学习现在已成为现代图像和语音识别、科学分析、数字制造和农场、金融建模以及在线产品、电影和社交兴趣推荐不可或缺的一部分。在许多情况下，ML 模型是通过 SML 进行训练的，计算模型可以利用编码的真实训练样本学习正确分类输入数据，或根据输入数据预测未来结果状态。训练样本包括已用正确的数据类或结果状态标记的代表性任务数据（例如图像、声音、运动数据）。然后使用这些训练样本来构建输入数据（例如图像中的像素）如何映射到正确的输出标签（例如猫或狗）的近似模型。训练后，模型的有效性将针对训练期间未提供的数据进行测试，有效的模型能够将学习到的输入输出关联推广到未见过的数据。

人工神经网络和长短期记忆网络。

SML 模型可以通过多种方式实现，例如，使用决策树、支持向量机或此处特别重要的人工神经网络 (ANN)。一般来说，人工神经网络是基本单元、节点的组合，这些单元被分组在互连的层中，其中节点具有不同的激活函数，并且节点之间的连接可以具有不同的权重。典型的 ANN 包括输入层和输出层，中间有 1 个或多个“隐藏层”（更深的 ANN 具有更多隐藏层）。训练 ANN 通过 SML 对输入输出关联进行建模需要找到将输入数据映射到正确的输出类或状态预测的网络参数（权重和偏差）的组合。这是通过迭代评估 ANN 的正确输出和预测输出之间的误差（通过损失函数）并使用称为反向传播的过程调整网络参数以最小化此误差来实现的（更多详细信息请参阅例如）。

人工神经网络有多种类型。与此相关的是一种称为长短期记忆 (LSTM) 网络的 ANN，它是循环神经网络的一种形式，除了节点层之间的前馈连接外，还包括反馈连接。这些反馈连接使人工神经网络能够处理和保留有关连续输入序列的信息。因此，LSTM 通常用于时间序列预测任务，其中需要处理过去和当前的输入状态才能正确预测未来状态。LSTM 适用于预测人类行为，因为人类行为决策基于动态（时变）任务信息的评估，因此，未来状态行为或行为决策的预测需要处理任务相关状态输入数据的序列。

可解释的人工智能。

尽管近年来人工神经网络的实用性和有效性不断提高，但人工神经网络内大量的连接权重和激活函数的非线性、泛化限制和复杂的决策边界，特别是在深度人工神经网络中，使得直接访问变得困难输入特征如何与输出预测相关。因此，人工神经网络通常被称为“黑盒”模型。然而，为了更好地理解和解释人工神经网络和其他黑盒模型的有效性，以及对更加道德和透明的人工智能系统不断增长的需求，人们对可解释的人工智能技术的应用和开发重新产生了兴趣，例如如 LIME、DeepLIFT、LRP 以及最近的 Shapley Additive exPlanation (SHAP)，我们在这里使用它。

这些技术通过推导输入特征对输出状态影响的线性解释函数，使黑盒模型的内部过程变得易于理解。例如，SHAP 算法将每个输入特征与 SHAP 值配对。SHAP 值越高，该特征对输出状态的影响越大。鉴于 SHAP 值是局部准确的，我们可以通过计算特征在用于评估模型准确性的测试集上的平均重要性来得出全局特征重要性的度量。结果是给定输入到输出关联的平均 SHAP 值，它捕获给定输入特征对于给定输出预测的总体重要性。

目前的研究。

当前的研究有三个主要目标：（1）研究使用 SML 训练的 LSTMlayered ANN 模型（以下简称 LSTM 模型）来预测人类在熟练的联合行动中的决策；（2）通过确定哪些输入信息（特征）对经过训练的 LSTM 模型的输出预测影响最大，展示如何使用 SHAP 来揭示支持人类在熟练的联合行动过程中做出决策的任务信息；（3）应用这些技术来解释新手和专家玩家在玩模拟的快节奏羊群游戏时决策过程之间的差异。

牧群任务涉及两组自主代理的交互 - 需要一个或多个牧群代理来围住并包含一组异质目标代理。此类活动在日常生活中无处不在，并提供了日常熟练的联合或多主体行为的典型示例。事实上，虽然最明显的例子涉及农民放羊或牛，但类似的任务动态定义了教师在博物馆中聚集一群幼儿或消防员从建筑物中疏散一群人。

在当前的研究中，我们对来自 的数据进行了建模，其中一对玩家控制虚拟牧民代理，将分散在游戏场周围的四头虚拟牛（以下称为目标）围成一个位于中心的红色收容区域。的游戏场。该任务在一个大触摸屏上呈现，玩家使用触摸笔控制他们的虚拟牧民（图1a）。当牧民到达目标一定距离内时，目标就会被人类控制的牧民击退。不受影响时





图 1.(a) 放牧任务和实验设置。(b) 数据回放和编码应用程序的屏幕截图，用于识别牧民在每个时间步正在围堵的目标。蓝色和橙色的点是牧民，白色的点是目标。每个目标上方的文本标签指定目标编号（即 1 到 4）。透明的红色区域是遏制区域，对于此处使用的数据而言，该区域始终位于游戏场的中心。(b) 右下角的插入面板是目标编码面板，其中 UD = 无目标。有关更多详细信息，请参阅正文。

对于牧民来说，目标的运动受布朗运动控制，目标在游戏场上随机（分散）徘徊。

为了成功地将目标圈入收容区域，之前的研究表明，有效的任务执行需要玩家通过将任务空间动态划分为两个责任区域来协调他们的目标选择决策，然后每个玩家一次将一个目标圈入自己的区域。相应的责任区域，直到所有目标都被限制在收容区域内。然而，迄今为止，之前的研究还没有明确探索或建模玩家做出目标选择决策的过程，也没有明确哪些状态信息调节这种决策行为。假设玩家的 (a) 目标选择决策是在其牧民的运动中指定的，并且 (b) 玩家使用目标和牧民状态的运动学信息（例如相对位置、速度）来做出目标选择决策，我们期望 LSTM 可以通过 SML 进行训练，以使用目标选择之前的牧民和目标状态输入特征的短序列来预测这些目标选择决策。我们预计目标选择决策可以在玩家制定目标选择决策之前进行预测，并且考虑到专家的表现明显优于新手（以及补充信息，第 1 节），我们还预计经过训练的 LSTMNN、专家和 LSTMNN，新手模型将具有特定的专业知识。最后，我们期望 SHAP 可以用于识别专家和新手牧民决策过程中的差异，或者更具体地说，专家或新手目标选择行为的 LSTM 模型在进行预测时如何准确地加权任务信息（特征输入）。

结果

假设玩家可以选择圈养目标，预测人类牧民的目标选择决策对应于 5 标签预测问题，其中 ID = 1、2、3、4 对应于实际目标，ID = 0 对应于无目标。

为了使用 SML 训练 LSTM，我们从专家-专家对和成功完成二元羊群任务的新手-新手对的数据记录中提取时间序列数据。仅使用来自成功试验的数据。对于每次试验，状态数据都是从任务开始时到玩家将所有四个目标限制在收容区域内期间提取的。在每个时间步骤中，牧民所围捕的目标均由研究助理使用自定义编码软件包手动标记，而对研究的真实目的视而不见（参见图 1b 和“方法”了解更多详细信息）。根据生成的标记时间序列数据，包含 48 个输入特征的训练样本的长度为  $t$  到  $t$ ，其中  $t - t = T$ ， $T$  的长度对应于 25 个时间步长（即  $t = t - 25$  个时间步长）或 1 系统状态演化的  $s$ 。48 个状态输入特征是牧民之间以及牧民与 4 个目标之间的相对径向和角距离，每个牧民和目标距收容区域的径向和角距离，以及牧民的径向速度、径向加速度和运动方向。每个牧民和目标。

预测未来的目标选择决策。

LSTM 模型经过训练，可以在给定长度为  $T$  的特征输入序列（ $T > 0$  时间步长）的情况下预测牧民将在  $t$  处圈养的下一个目标 ID。请注意， $T = 1$  对应于预测牧民在下一个时间步（相当于未来 40 毫秒）将圈养的目标，因此，只需预测牧民已经做出和/或当前正在制定的目标选择决策。在这里，我们展示了经过训练以在两个较长预测范围（即  $T = 16$  和  $32$ ）下预测目标选择决策的模型的结果，这分别对应于预测牧民在未来 640 毫秒和 1280 毫秒将圈养的目标（用于比较）出于目的，我们还训练了  $T = 1$  和  $8$  的模型，请参阅补充信息第 3 节。

重要的是， $T = 16$  和  $32$  涉及在玩家的决定或行为意图被制定或通常在输入数据序列  $T$  中观察到之前预测目标选择决策。通过计算玩家切换目标时在目标之间移动所需的平均时间来验证这一点，新手牧民的平均目标间移动时间为  $556$  毫秒，专家牧民的平均目标间移动时间为  $470$  毫秒（见补充信息，第 2 节）。训练单独的 LSTM 来预测新手和专家牧民在每个预测范围内的目标选择决策。图 2 报告了在 10 组测试数据样本（即训练期间未使用的样本）上评估的每个 LSTM 的混淆矩阵。重要的是，对角线上的值表明每个目标 ID 可以在  $90\%$  到  $97\%$  之间被正确预测。事实上，独立于预测范围和玩家专业知识，每个 LSTM 都以超过  $94\%$  的平均准确度预测哪个目标牧民会被围住（有关更多预测指标，请参阅表 1，在“方法”中定义）。

预测不同的目标选择行为。

回想一下，用于进行目标选择预测的数据样本是放牧系统状态演化的向量时间序列，其中  $t \in [t, t]$ ，其中  $t - t = T$ ，并且预测输出被选为目标 ID。当  $T = 0$  时将在  $t$  被围堵的目标。重要的是要认识到，在时间间隔  $T$  期间，人类牧民可以连续围堵相同的目标代理或在不同目标之间转换。在这里，我们将它们分为非过渡性和过渡性

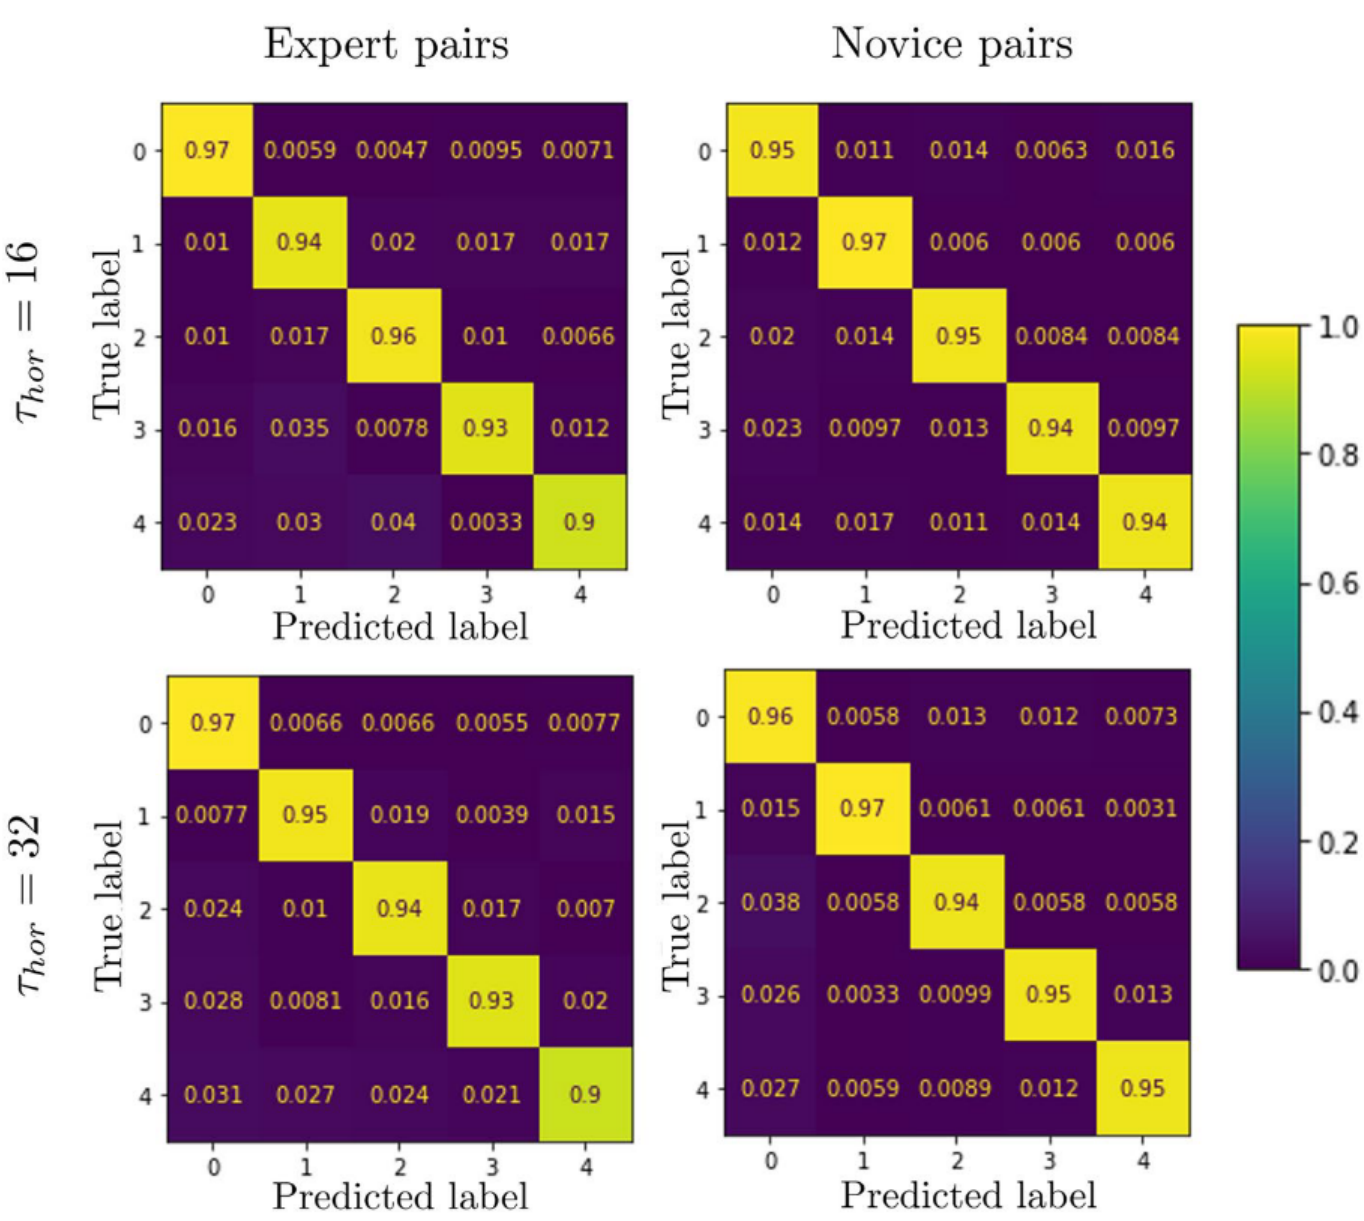


图 2. 针对每个专业水平和预测范围，在 10 组  $N = 2000$  个样本上测试的训练预测模型的混淆矩阵。对角线上的值表示正确预测的测试样本部分。

	准确性	精确	记起	F1成绩	MI
$\tau = 16$ (640 ms) 预测范围					
新手	$95.33 \pm 0.2$	$95.18 \pm 0.2$	$95.25 \pm 0.2$	$95.2 \pm 0.2$	$84.16 \pm 0.5$
专家	$95.2 \pm 0.4$	$94.17 \pm 0.6$	$94.5 \pm 0.5$	$94.3 \pm 0.5$	$84.9 \pm 0.5$
$\tau = 32$ (1280 ms) 预测范围					
新手	$95.75 \pm 0.5$	$95.42 \pm 0.5$	$95.5 \pm 0.5$	$95.45 \pm 0.5$	$83.24 \pm 1.04$
专家	$94.66 \pm 0.5$	$93.2 \pm 0.7$	$93.34 \pm 0.8$	$93.25 \pm 0.7$	$81.32 \pm 1.5$

表 1. 专家模型和新颖模型的平均性能 [%] 作为预测范围的函数，在 10 组  $N = 2000$  个样本上进行测试。MI 互信息。



分别描述行为序列。此外，在  $T$  处，牧民可能会围堵在  $T_{or}$  末端围堵的同一目标，也可以切换到不同的目标。在这里，我们将这两种可能性分别归类为非切换行为和切换行为。总的来说，这定义了目标选择行为（或数据样本类型）的四个不同的子类别（子类），如图3所示。

在专家和新手数据集中观察到的不同目标选择行为的样本分布作为预测范围  $T = 16$  和  $32$  的函数，如图 4a 所示。有趣的是，专家数据包含很高比例的非转换-非转换行为 (69%)，而新手数据集包含比专家更均匀的样本类型分布，特别是在  $T = 32$  时。这表明专家既与新手相比，他们在不同目标之间转换和切换的频率较低，并且与新手相比，他们在锁定给定目标方面更加持久。对于目标选择预测更重要的是，由于训练期间每种样本类型的表示不均匀，样本类型分布的差异可能会影响模型的准确性。也就是说，使用随机选择的训练集训练的模型对于代表性不足的行为类型表现出较低的准确性；例如，与非转换-非转换行为相比，转换-转换行为的模型精度会较低。补充信息第 2 节对此进行了说明。在图 4 中，我们展示了当使用样本类型的代表性分布训练模型时，模型准确性如何与子类相关。

因此，这里报告的 LSTM 模型是使用包含随机选择但均匀（平衡）分布的样本类型的训练集进行训练的，以便目标选择行为的每个子类在训练期间得到平等的代表。此外，除了检查整体模型准确性之外

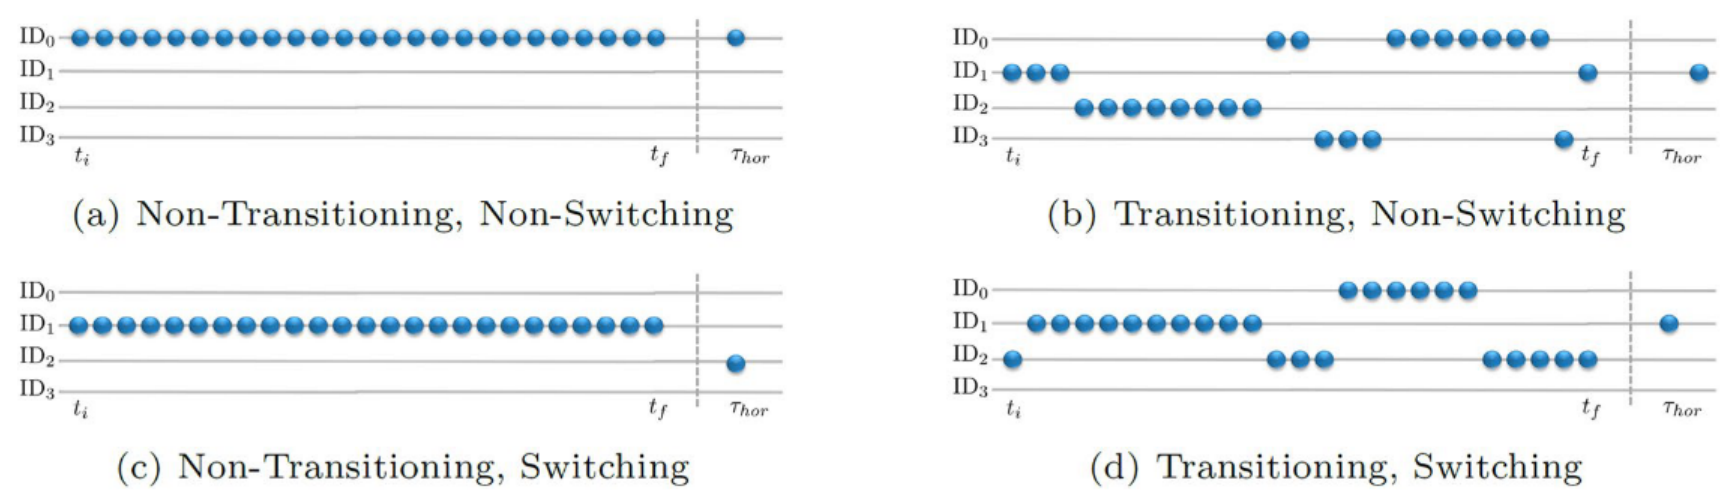


图 3. 目标选择行为的不同子类别的图示，这也反映了用于模型训练和测试的四种不同类型的数据样本。非转换 (a, c) 和转换 (b, d) 对应于在输入序列  $T = t \in [t, t]$  期间，较硬的对象是相同目标还是不同目标。非切换 (a, b) 和切换 (c, d) 分别对应于牧民在  $T$  和  $t$  时是否圈养相同或不同的目标。

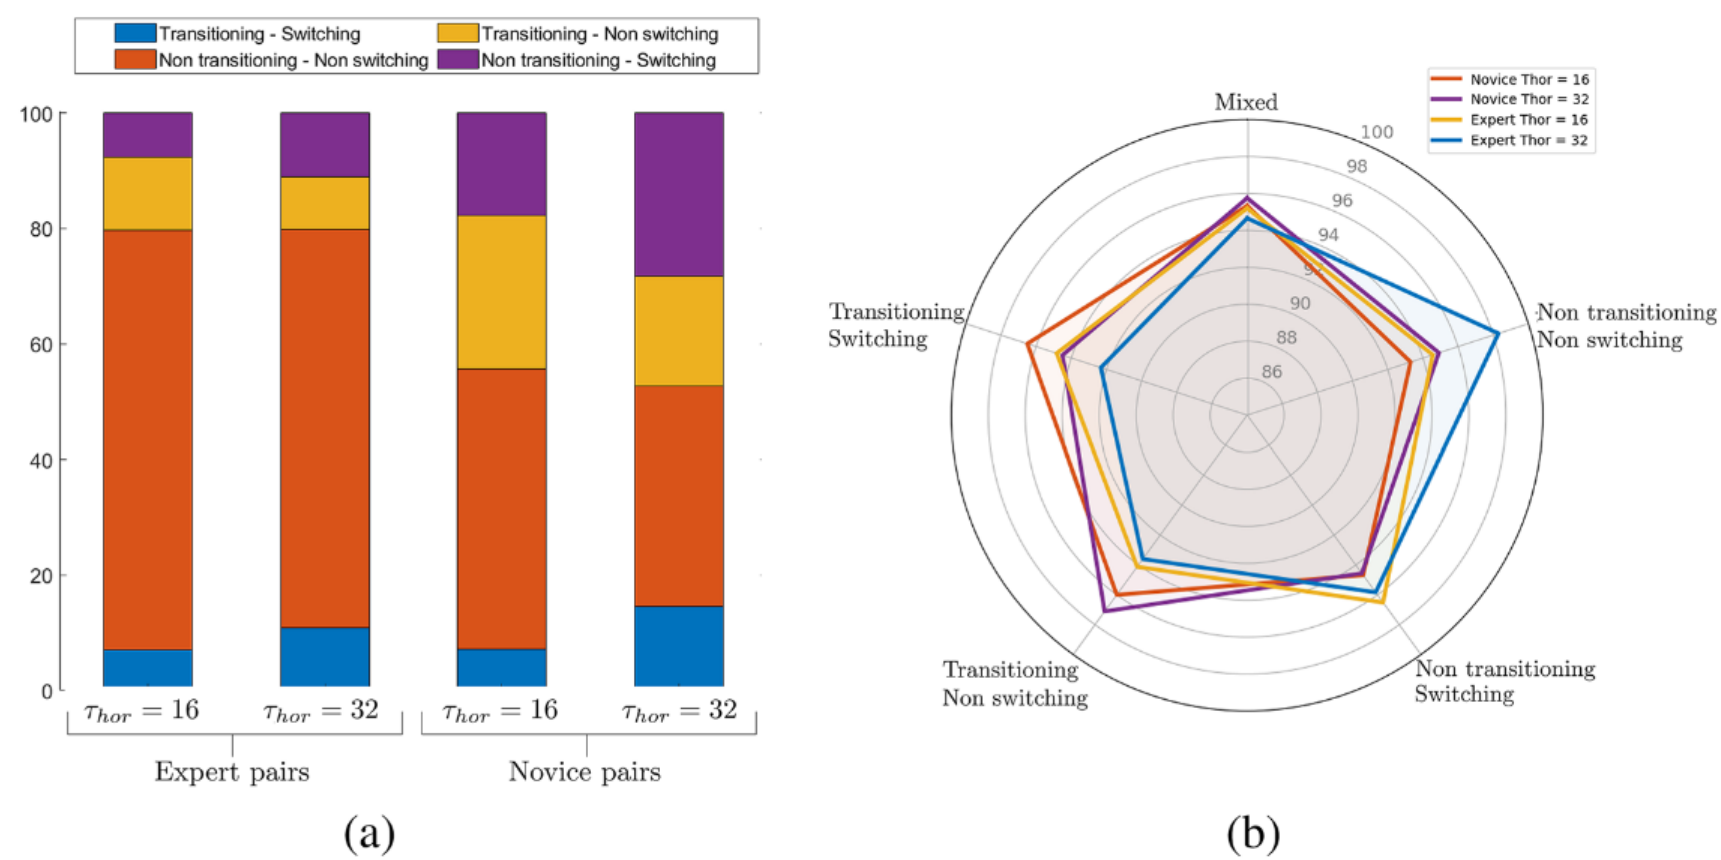


图 4.(a) 目标选择的不同子类别（样本类型）作为专业知识水平和预测范围的函数的分布。(b) 使用均匀分布的训练样本（即训练集包含每种样本类型的 25%）训练的模型的一般（混合）和样本特定准确度，作为专业知识水平和预测范围的函数。准确度值范围为 92.3% 至 98.2%，总体平均准确度为 95.23%，而互信息范围为 66.6% 至 93.5%，总体 MI 得分为 81.5%。

目标 ID 的函数（见图 2 和表 1），在 T= 16 和 32 时预测专家和新手目标选择决策的 LSTM 模型也针对  $N \geq 1$  个由以下任一组成的新测试集进行了测试：(i) 非转换-非转换，(ii) 非转换-转换，(iii) 转换-非转换，(iv) 转换-转换样本。请注意，每个测试集包含 2000 个测试样本，因此用于模型测试的测试集 N 的数量从 1 到 10 不等，并且是训练后可用样本数量的函数（即来自模型期间未使用的样本集）训练；详细信息请参见“方法”。

图 4 显示了每种样本类型的平均模型准确度与专业水平和预测范围的函数关系；有关模型精度和互信息值作为样本类型函数的详细列表，请参阅补充信息，第 2 节。4. 结果表明，所得模型的准确性基本上与样本类型无关。更具体地说，对于 T = 16，LSTMnovice 模型的每种样本类型的准确度介于 93.3% 和 98.2% 之间，LSTMexpert 模型的每种样本类型准确度介于 93.6% 和 97.11% 之间，平均混合样本类型准确度为 95.33% ( $\pm 0.2$ ) 和 95.2% LSTMnovice 和 LSTMexpert 模型分别为 ( $\pm 0.4$ )。同样，对于 T= 32，LSTM 模型的每种样本类型的准确度介于 94.56% 和 96.51% 之间，LSTMexpert 模型的准确度介于 92.32% 和 96.5% 之间，平均混合样本类型准确度为 95.75% ( $\pm 0.5$ ) 和 94.66% ( $\pm 0.5$ ) 分别适用于 LSTMnovice 和 LSTMexpert 模型。

专家和新手预测的特异性。

后者的结果提供了明确的证据，表明 LSTM 模型可以准确预测专家和新手牧民的未来目标选择决策，无论未来要圈养的目标与  $T \leq 0$  时圈养的目标是否相同或不同。专家和新手的表现同等重要的是确定相应的 LSTM 模型是否针对专业知识。这是通过比较专家训练的 LSTM 模型的性能来测试的，该模型试图预测新手目标选择决策，反之亦然。正如预期的那样，当使用一种专业知识训练的 LSTM 来预测从相反专业知识中提取的测试样本时，模型性能下降到接近或低于机会水平（见图 5），从而确认模型确实是特定于专业知识的。更具体地说，对于 T = 16，LSTMexpert 模型预测新手样本的平均准确度仅为 40.68%。同样，LSTMnovice 模型仅预测专家样本，平均准确率为 57.7%。对于 T= 32，专家到新手的预测平均准确度下降到 37.66%，新手到专家预测的平均准确度下降到 58.1%。

识别专家和新手目标选择决策的差异。

与不同专业水平（见图 5）相比，在相同专业水平（见图 1）上训练和测试的 LSTM 模型的性能存在显著差异，这表明新手和专家 LSTM 模型对输入状态变量的加权不同。回想一下，这里特别令人感兴趣的是是否可以使用可解释的人工智能技术 SHAP 来发现这些差异。因此，对于每个模型，我们计算训练集子集中每个样本的 SHAP 值，然后使用平均 SHAP 值，根据每个输入特征的预测重要性对其进行排序。

在评估哪些特定输入特征的权重不同之前，我们首先使用 Kendall 等级相关系数（Kendall  $\tau$ ）计算不同 LSTM 模型之间 SHAP 值排名的顺序关联，其中  $\tau = 0$  对应于不存在关联。

请注意，虽然  $\tau = 0$  是零假设，并且不能从非显著性结果中得出结论，但它确实提供了对排名顺序独立性的稳健且直观的评估， $\tau = 1$  对应于完美关联（匹配排名），并且  $\tau = -1$  对应于相反的排名顺序（负关联）。更多的




图 5. 12 个不同的一致（新手-新手、专家-专家）或不一致（新手-专家、专家-新手）N= 2000 个样本的测试集的专家模型和新颖训练模型的平均准确度 (%)。 \*\*表示显著的配对样本 t 检验差异为  $p < 0.01$ 。请注意，当在相同的专业水平（即新手-新手和专家-专家（所有  $p > 0.1$ ））进行测试时，LSTMnovice 和 LSTMexpert 模型对于两个预测范围的准确性没有显著差异。



具体来说，我们在每个预测范围的新手和专家 LSTM 模型之间，根据完整输入特征集的 SHAP 排名以及 SHAP 排名的前 10 个特征计算了 Kendall  $\tau$ 。与新手和专家在做出目标选择决策时使用不同状态信息的预期一致，该分析显示，对于  $T=16$  和  $32$ ，新手和专家 SHAP 排名之间几乎没有关联，平均  $\tau=0.08$  ( $p>0.45$ )  $T=16$  且  $\tau=-0.09$ , ( $p>0.4$ ) 对于  $T=32$  (有关 Kendall  $\tau$  值的详细摘要，请参阅补充信息第 5 节)。

为了强调哪些输入特征对目标选择预测影响最大，图 6 说明了非零预测输出 (即  $ID=1$  到  $4$ ) 和  $ID=0$  预测输出的不同输入特征的平均排名，其中不同输入要素定义为输入要素类 (例如，距牧民的距离、距共同牧民的距离、距收容区域的距离、速度等) 和代理类型的函数。注意，目标预测对应的玩家被称为牧民，玩家的伙伴被标记为 coherder，预测目标是预测在  $T$  时被牧民围住的目标，其他目标对应于目标预计不会在  $T$  处聚集 (参见补充信息，第 2 节)

6 有关 SHAP 特征值的详细摘要)。请注意，我们将插图和分析分为  $ID=0$  和  $ID=0$ ，因为决定选择特定目标进行围堵和选择不围堵目标之间存在质的差异，后者对应于一段时间优柔寡断，一段时间的目标间切换，或者决定当时不需要锁定任何目标。同样重要的是要认识到，如何将 SHAP 结果解释为预测范围的函数，存在着巨大的差异。尽管准确预测牧民未来的目标选择决策提供了基于 SML 的 LSTM 建模的预测能力的令人信服的证据 (以及人类行为的潜在稳定性或可预测性)，但在做出决策之前提前预测这些决策可以对牧民实际使用的信息提供的了解较少。如上所述，反之亦然，对于较小的预测范围，输入特征和模型预测之间的映射也可能不太了解牧民用于做出目标选择决策的信息，因为牧民可能已经制定了一项决策。

对于目前的工作，我们继续关注  $T=16$  和  $32$  (即分别为  $640\text{ ms}$  和  $1280\text{ ms}$ )，因为这两个预测范围似乎提供了牧民目标时间尺度的下限和上限的良好近似值选择决定。这再次受到对玩家目标间移动时间的分析的启发，如上所述，对于专家和新手来说，该时间平均小于  $600\text{ 毫秒}$ 。更具体地说，对于专家来说， $75.16\%$  的目标间移动时间小于  $640\text{ 毫秒}$ ， $97.38\%$  低于  $640\text{ 毫秒}$ 。

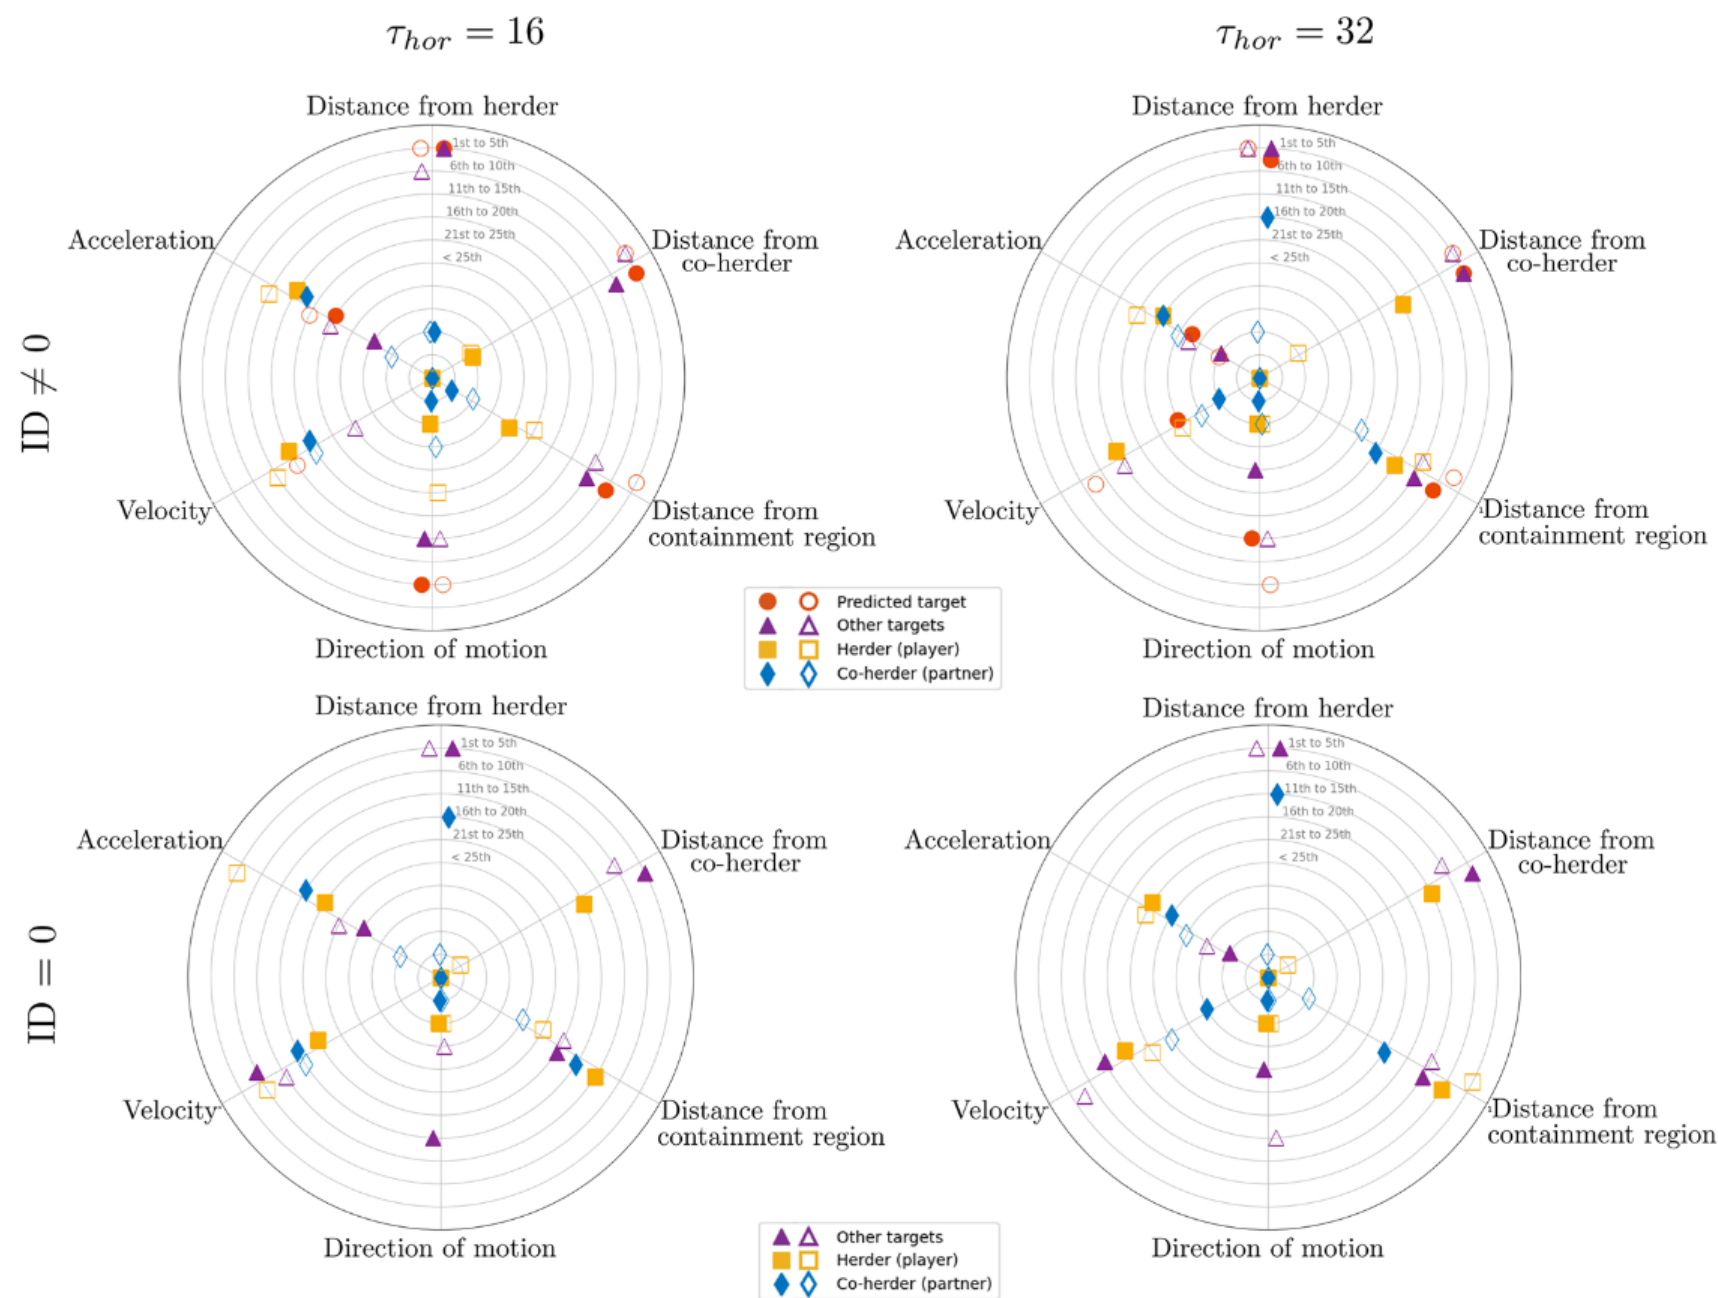


图 6. 目标预测的 SHAP 结果 (顶行)  $ID=0$  (即  $ID=1$  到  $4$ ) 和 (底行)  $ID=0$ ，作为预测范围和专业知识的函数 (新手 = 空形状，专家 = 填充形状)。要素类型列在顶点上。径向轴表示平均排名位置，使得“第一到第五”表示始终或几乎总是排名前五的特征。

1280 毫秒同样，对于新手来说，69.54% 的目标间移动时间小于 640 毫秒，91.36% 小于 1280 毫秒（参见补充信息，第 3 节）。因此，考虑到任务的快节奏性质以及牧民通常在行动开始之前决定下一个要圈养哪个目标的假设，似乎大多数牧民目标选择决策都是在这个 640 到 1280 毫秒的窗口内做出的。

对于目标 ID 6 = 0 的预测，对图 6a 的仔细检查表明，牧民与预测目标之间以及牧民与其他（非预测）目标之间的相对距离始终被确定为关键输入特征。专家和新手预测。事实上，这些特征几乎总是平均排在前 5 个特征内，与预测范围无关。预测目标与收容区域的距离也几乎总是被列为前 10 个特征，与专业知识和预测范围无关。有趣的是，这些结果与先前开发的启发式目标选择模型一致，其中假设完成此处探索的相同放牧任务的人类牧民选择（a）距离收容区域最远，但（b）离自己更近的目标比他们的共同牧人。因此，当前的结果为这些先前的假设提供了实证支持。

回想一下，肯德尔  $\tau$  分析的结果发现新手和专家之间的排序相似性非常小。鉴于后者的 SHAP 结果，这意味着虽然专家和新手决策似乎是基于相似的目标距离信息，但目标距离作为要素类函数的特定重要性顺序在专家和新手中是不同的。

事实上，对专家和新手的前 10 个特征排名的仔细检查（参见补充信息，第 6 节）表明，对于专家目标选择预测，目标与共同牧民的距离始终被列为最重要的特征，而对于新手来说，目标与其自身（即牧人）的距离通常被列为最重要的特征。尽管这种差异可能看起来很微妙，但它表明专家们更了解哪些目标更容易被他们的共同牧民围困。

目标 ID = 0 时的 SHAP 结果进一步支持了后一个结论，其中目标与玩家同伴的距离始终被专家列为前 5 个特征，但对于新手而言则不然；见图 6b。也就是说，专家不圈养目标的决定似乎更均匀地取决于目标与自身的距离（即与牧民的距离）及其共同牧民的距离，而新手的决定则更受目标距离的影响来自他们自己。这再次表明，与新手相比，专家更了解共同放牧者能够最好地实现哪些目标选择决策。

与最近的结果一致，SHAP 分析表明，有关预测目标运动方向的信息在专家和新手的目标选择决策中也发挥着重要作用。然而，专家和新手预测之间的另一个细微差别是，与新手相比，这一发现对于专家来说更为明显，预测目标的运动方向对于新手来说平均排名前 10 个特征，而对于新手来说则排名前 20 个特征。T = 16 和 32 的专家的平均值。对于最短预测范围内的专家目标 ID = 0 预测，运动方向总体上的权重也更大。这意味着专家的目标选择决策更容易受到目标是否移向或远离收容区域的影响。事实上，任务成功的关键是确保目标向收容区域移动，无论目标与收容区域的距离如何（假设目标被限制在定义的“围栏”边界内移动）。因此，选择围住正在远离遏制区域的较近的目标通常比选择较远但正在向遏制区域移动的目标要好。

最后，专家和新手预测的 SHAP 结果之间的另一个差异与牧民加速度和速度的重要性有关。事实上，这些特征经常被列为新手预测的前 15 个特征，特别是当 T= 16 时的无目标预测。鉴于 29.54% 的新手目标间移动时间大于 640 ms，这个结果可能是由于新手 LSTM 模型只是学习将新手牧民的运动信息映射到目标间运动期间发生的目标 ID = 0 的时段。也就是说，这并不表明新手牧民受到自己的速度或加速度的影响，这可能是由于与专家相比新手的行动决策时间尺度和目标间运动较慢的结果。当 T= 32 时，发现牧民速度对于新手预测不太重要，这与这种可能性是一致的。因此，回到什么预测范围最能捕捉牧民决策时间尺度的问题，后一个结果表明，T=32预测范围的 SHAP结果可以更好地反映新手牧民在做出目标选择决策时所使用的信息。

讨论

当前的研究利用基于 SML 的 LSTM 建模和可解释的人工智能方法的最新进展来建模和理解执行复杂、快节奏的多智能体羊群任务的专家和非专家人类参与者的决策活动。结果表明，短（1 s）状态信息序列（T）可用于训练 LSTM 模型，以准确预测专家和新手玩家的目标选择决策。重要的是，模型预测是前瞻性的， $T \geq 16$  的大多数预测发生在牧民的目标选择决策在状态输入序列中制定或可观察之前。值得注意的是，模型有效性并不限于  $T = 1$  s 或  $T \geq 16$ 。如补充信息第 2 节中所述。如图 3-4 所示，使用 0.5 至 2 s 的序列长度训练的 LSTM 模型可以在 20 ms 至 2.56 s 的预测范围内准确预测（95% 以上）目标选择决策。此外，尽管  $T \geq 16$  时的正确预测并不能提供明确的证据表明这些预测先于牧民意图，但这种可能性似乎很可能，因为人类参与者在熟练行动期间做出的行动决策是对任务展开动态的自发调整响应，并且，对于此处研究的知觉运动任务类型，通常仅发生在动作开始前 150 至 300 毫秒。一个重要的含义是，当前的建模方法可用于在任务训练和实时任务参与期间对人类行为决策进行预期校正，以及开发更多“类人”模型



人工或机器人代理能够在人机交互环境中稳健地预测并相互调整人类合作者的行为。

未来研究的一个有趣途径是探索当前建模方法在可变预测范围内预测人类决策事件的程度。例如，对于当前任务上下文，这相当于预测目标切换决策。未来的研究还可以探索预测范围长度和准确性之间的函数关系，作为任务时间尺度及其决策动态的函数。有趣的是这里采用的方法是否可以从这里探索的快节奏决策时间尺度适应涉及慢得多的决策时间尺度的任务（例如，涉及动作决策需要花费数十秒或几分钟的任务）。

当前研究的一个关键发现是，经过训练的 LSTM 模型是特定于专业知识的，因为当训练数据和测试数据的专业水平不匹配时，预测性能会下降到接近机会水平。熟练的参与者的决策是参与者经过训练的对最能指定哪些行动可能性将确保任务完成的信息的协调的函数，这是由于专家和新手 LSTM 模型对输入特征的权重不同而导致的。这些差异是使用 SHAP 来识别的，平均 SHAP 特征排名表明，与新手相比，专家更容易受到同伴状态信息的影响，并且也更能适应运动信息的目标方向。再加上发现专家在目标之间转换的频率低于新手，这表明专家更能适应能够更好地说明放牧系统集体状态的信息，包括何时以及什么目标可以由他们自己和他们的共同牧民进行围堵。

据我们所知，之前的研究还没有采用可解释的人工智能技术来尝试理解和解释人类行动者在熟练行动中的决策行为，更不用说识别专家和新手行动者之间的差异或协调联合背景下的实验条件了。-行动。迄今为止，可解释人工智能的研究主要集中在这些技术使人工智能模型更容易被人类用户理解以及论证或增强人类用户的决策能力的能力。而且，虽然这些工作经常与人类决策的认知和心理学模型和理论联系起来，但尚未考虑可解释的人工智能在专门理解人类决策的方式、原因和时间方面的效用（例外情况，请参见）。我们公开承认，采用可解释的 AI 和 SML 训练的 LSTM 来理解人类决策是基于两个基本假设：(i) 用于模型训练的输入特征包括人类参与者使用的信息变量，以及 (ii) 映射输入特征权重和模型预测之间的关系与人类行为决策背后的实际信息决策映射是同构的；并且这些假设需要在未来的工作中得到验证。

我们还承认，这里探索的任务为玩家（牧民）提供了完整（全球）状态信息的访问权限。也就是说，在任何给定时间，牧民都可以（或多或少）总是看到其他牧民和所有目标代理的位置和动作。因此，未来研究的另一个有趣的途径是探索当无法完全访问任务环境或系统的状态时，本文提出的 SML 和可解释的人工智能方法是否也可以用于建模和理解人类决策。例如，可以通过尝试对完成第一人称放牧游戏（例如）的人类玩家的目标选择决策进行建模来解决这个问题，其中每个牧民仅拥有有关状态的本地（第一人称视野）信息。任意时间点的任务环境。

未来的研究还应该将此处采用的 SHAP 技术的有效性与其他可解释的人工智能工具（例如 LIME、Deep-Lift 或 LRP，以及可解释的 Transformer 技术）进行比较。未来的工作还可以探索使用可解释的人工智能来理解经常发生优柔寡断的情况下的决策的可能性，以及是否可以使用可解释的人工智能对分类错误或不正确的决策预测背后的输入输出映射进行分析了解无效的决策。

尽管需要未来的工作，但当前的研究提供了初步证据，表明可解释的人工智能技术可以为理解人类参与者的决策过程提供强大的工具，包括哪些信息最能支持最佳任务绩效。此外，尽管我们将当前研究的重点限制在与视觉运动协调任务相关的信息变量上，但这里提出的方法可以应用于广泛的任务和设置（即视觉、听觉、触觉、语言、ETC。）。因此，对于基础科学研究和决策评估工具的应用开发的潜在影响可能是无限的。

方法

本研究采用的所有方法和程序均符合麦考瑞大学人类研究法规，并得到麦考瑞大学伦理委员会的批准（协议 6457）。参与原始数据收集研究的所有受试者都获得了知情同意书（，之前的研究涵盖在上面列出的相同伦理协议下）。

人类放牧任务和数据。

当前的研究采用了来自联合行动畜牧实验的新手和专家的人类表现数据。放牧任务（游戏），使用Unity-3D游戏引擎（Unity Technologies LTD, CA）开发，需要配对（ $N = 2$ ）人类参与者（玩家）控制虚拟牧群代理围堵并遏制  $N = 4$  个在位于游戏场中心的指定收容区域内随机移动的目标特工。该任务是在 70 英寸大型触摸屏显示器上执行的（见图 1a），人类参与者使用触摸笔控制牧民代理的运动位置。当不受牧民代理影响时，目标的运动动力学由布朗运动定义，而当受到牧民代理影响时，目标将朝远离牧民的方向移动

代理人。在任务执行过程中，所有牧民和目标的位置和速度（以及其他一般游戏状态）以 50 Hz 的频率记录。两人最多有 2 分钟的时间将目标限制在收容区域内，如果两人能够将目标限制在收容区域内 20 秒，则任务成功。

实验设置和数据收集过程的完整详细信息可以在 中找到。  
新手数据是从 10 个不同新手对进行的 40 次成功试验中提取的（每对 4 次成功试验）。从每次试验中，我们提取了从任务开始到所有四个目标代理首次被包含在指定收容区域内的状态数据；也就是说，当牧民第一次将所有特工集中在收容区域内时。剩余的试验数据被忽略，因为玩家在目标群体被收容后将其视为单一实体，并且不再出现单独的目标选择决策。请注意，如果人类牧民在数据收集之前不熟悉放牧任务，则被视为“新手”。新手重复该任务，直到完成新手数据集中包含的 4 次成功试验（平均每对有 8 次不成功的试验）。  
专家数据是从 3 对具有丰富经验（完成超过 100 次成功试验）的人类玩家（即来自 的几位作者）执行的 48 次成功试验中提取的。与新手数据一样，我们提取了从任务开始到所有四个目标代理首次被包含在指定收容区域内的状态数据。

**状态输入功能。**  
从原始新手和专家数据集中记录的位置和速度数据中，我们提取并导出以下  $N=48$  个状态变量：

- 牧民之间的径向距离和角距离  $(\Delta, \Psi)$  ,
- 目标  $i$  距牧民  $j$  的径向距离和角距离  $(\Delta, \Psi)$ ,
- 牧民  $j$  或目标代理  $i$  距收容区域中心的径向距离和角距离  $(\Delta, \Psi)$ ,
- 牧民径向速度和加速度  $(\dot{r}(t), \ddot{r}(t))$  和目标代理  $(\dot{\rho}(t), \ddot{\rho}(t))$ ,
- 牧民和目标代理的运动方向。

**目标编码。**  
一名付费研究助理对研究目的很天真，通过交互式数据回放 Unity3D（版本 2018LTS）应用程序（该应用程序回放原始记录的数据），对特定牧民在每个时间点正在围堵的目标（或不围堵）进行编码（分类）。设置（见图 1b）。数据回放速度可以降低到 1/8 速度，并且可以逐帧步进，每个目标都用固定数字（1 到 4）进行视觉标记。在每个时间步长，特定人类牧民所围捕的目标代理均由研究助理用整数进行编码~

$$i \in [0, ^N], \text{ 和 } i = 0 \text{ 表示“没有目标代理被围堵”并且 } i = 6 = 0 \text{ 是类别 ID}$$

目标代理在该时间步被围住。

**人类目标间移动时间。**  
为了确定专家和新手牧民从一个目标移动到下一个目标所需的时间，我们计算了在目标 ID = 1 到 4 之间切换时的目标间移动时间（即，我们忽略了从 ID = 0 到 ID = 0 的切换事件）。我们计算了从人类牧民移出当前目标的排斥影响区域到进入下一个目标的排斥影响区域的时间。更具体地说，目标间移动时间是牧民进入当前目标的排斥半径（即每个目标代理周围 0.12 m）的时刻与它们的相对距离正在减小的时刻之间的差值（以毫秒为单位），此时牧民离开先前围住的目标周围的排斥区域，并且他们的相对距离增加。除了上面的平均结果报告外，请参阅补充信息，第 2 节。图 2 为专家和新手牧民的目标间移动时间分布。

**训练和测试集数据。**

每个专业级别的所有成功试验数据都与相应的目标代码（ID 0 到 4）一起堆叠在经过共同特征处理的新手或专家数据集中。从所得的经过特征处理的新手和专家数据集中，我们随机提取了 2 组  $N=21,000$  个训练样本和 20 个测试集，每组  $N=2000$  个样本。算法 1 中报告了相应的伪代码。  
第一个训练集和 10 个测试集包含平衡比例的转换/切换样本（各 25%）。该数据集用于训练和测试此处介绍的模型。第二个训练集和其余 10 个测试集包含与整个数据集中相同比例的转换/切换样本，请参见补充信息第 2 节。3-5 有关使用后者不平衡训练集训练的信息。



算法1结果: CreateDataset

---

training set, validation set, test set

for each herder

for each trial data

调用 createDataset(herder, Trial data) 返回 seq, tar

附加到 seq sequences

附加到 tar targets

调用 splitSamples(sequences, Targets) 返回 training set, validation set, test set

这里，样本是指状态特征序列和目标标签代码对。序列由上面列出的 Nstate 变量的  $N=25$  个连续实例组成，在  $dt=0.04\text{ s}$  采样，覆盖  $T=1\text{ s}$  系统演化，标签是目标代理的 ID，在  $T=16dt$  和  $T=\text{距相应序列结束 } 32dt$  秒。在补充信息中，第二节。在图 3 中，我们还考虑  $T=0.5\text{ s}$  和  $T=2\text{ s}$  的值，将采样时间分别更改为  $dt=0.02$  和  $dt=0.08\text{ s}$ 。与结果中呈现的默认情况一样，使用这些不同 Tlength 训练的新手和专家模型在对来自相同专业水平（例如专家-专家）的数据进行测试时也获得了大于 95% 的准确度值，并且在来自相同专业水平（例如专家-专家）的数据进行测试时也获得了接近 50% 的准确度值。对不同专业水平（例如，新手-专家）的数据进行测试。

### LSTM 网络和模型训练。

对于专业知识和预测范围的每种组合，我们使用 Adam 优化和 K = 5 的分层 K 折交叉验证，训练了具有 Dropout 层的长短期记忆 (LSTM) 人工神经网络（代码可在 <https://github.com/github.com/github.com/kubernetes/2019/11/14/10/11/12/12/14/2017/12/14/10/14/10/10/2017/10/14/2017/12/14/10/14/10/10/2017/2017/20> 的专业知识和预测范围的预测范围进行训练。com/FabLtt/ExplainedDecisions）。我们使用贝叶斯优化来调整 Adam 优化器的学习率 ( $\alpha = 0.0018$ ) 和 LSTM 的超参数（即 LSTM 隐藏层的数量、每层神经元的数量和 dropout 率）。优化后的 LSTM 的输入层和输出 Dense 层的维度为 (T, N) 和 (T, ^ + 1)，分别。在中心，253、45 和 8 个神经元的 3 个隐藏 LSTM 层与相同维度的 Dropout 层交替。新手和专家模型的每个 LSTM 层的 dropout 率为 0.1145。对于每个 LSTM 层之间的 dropout 层，dropout 率为 0.0145。为了避免过度拟合，当验证集上的对数损失（惩罚错误预测）停止改善时，训练就会停止；验证集是随机提取的训练集的 10%。LSTM 是使用 Python 3.7.1 和 Tensorflow 库 (<https://www.tensorflow.org/>, 版本 1.15) 构建和训练的。算法 2 中报告了相应的伪代码。

算法	2	TrainAndEvaluateModel	结果:
trained model, performance metrics			
德伊内	kfoldCrossValidator		
用于调用generateModel()返回	each fold		trained model
调用训练后的 model.compile() 调用训练后的模型			
(训练集, 验证集) 以调用评估性能 () 返回			
each test sample			
			accuracy, precision, recall, f1

### 模型性能。

使用以下措施验证 LSTM 的性能：准确性 - 测试样本中正确预测输出的比例；精度——预测的有效性，即相关输出在预测输出中所占的比例；回想一下——预测的完整性，即预测的相关输出的部分。请注意，当 Precision 和 Recall 达到 100% 时，分别不存在假阳性输出和假阴性输出。此外，我们还报告了模型预测的 F1 分数，F1 分数（即精确率和召回率的调和平均值）的值较高，表示模型预测的精确度和鲁棒性。

shapley 附加解释。

给定一个样本，SHAP 算法为每个输入特征分配一个重要性值 (<https://github.com/slundberg/shap>，版本 0.31)。这是每个特征对实际预测输出和平均预测输出之间差异的贡献的估计。我们随机选择了  $N$  = 训练集中的 200 个样本作为背景集，即作为输入空间的先验分布，用于近似 SHAP 值的条件期望。我们对  $N$  = 6000 个用于评估性能的测试样本应用 SHAP DeepExplainer，并获得每个状态变量相应的 SHAP 值。为了导出相应的近似全局特征重要性度量（如图 6 所示），我们对每一类预测输出（即目标 ID）的测试集进行平均。算法 3 中报告了相应的伪代码。

算法3	<a href="#">ExplainModel</a>
结果:	<a href="#">shapvalues</a>
init background and samples as random subsets of training set	
调用 shap.DeepExplainer(训练模型, 背景) 返回	调用explainer.shap explainer 值(样本) 返回 shap values

数据可用性

当前研究使用的原始数据集和代码可在 <https://github.com/FabLtt/ExplainedDecisions> 获取。处理后的数据集、模型和详细的 SHAP 值可在 <https://osf.io/wgk8e/?viewonly=8aec18499ed8457cb296032545963542> 上获取。

收稿日期: 2022 年 8 月 30 日; 接受日期: 2023 年 3 月 17 日  
Published online: 27 March 2023

参考

1. Dale, R., Fusaroli, R., Duran, N. D. 和 Richardson, D. C. 人类互动的自组织。心理。学习。动机。 59, 43–95 (2013)。
2. Richardson, M. J. & Kallen, R. W. 对称性破缺以及人类多智能体协调和社会活动的情境出现。语境。定量。物理。心理。 1, 229–286 (2016)。
3. Sebanz, N. 和 Knoblich, G. 联合行动研究进展。电流。导演。心理。科学。 30(2), 138–143 (2021)。
4. Schmidt, R. C., Fitzpatrick, P., Caron, R. 和 Mergeche, J. 了解社会运动协调。哼。移动。科学。 30(5), 834–845 (2011)。
5. Sebanz, N. 和 Knoblich, G. 联合行动的预测：什么、何时、何地。顶部。认知。科学。 1(2), 353–367 (2009)。
6. Davids, K., Araújo, D., Seifert, L. 和 Orth, D. 运动专家表现：生态动力学视角。劳特利奇体育专业手册, 130–144 (2015)。
7. 理查森, M.J., 马什, K.L.和巴伦, R.M.判断和实现内心和人际可供性。J.Exp。心理。哼。感知。履行。 33(4), 845 (2007)。
8. Sebanz, N., Bekkering, H. 和 Knoblich, G. 联合行动：身体和思想一起运动。趋势认知。科学。 10(2), 70–76 (2006)。
9. 维斯珀, C.等人。联合行动：心理表征、共享信息以及与他人协调的一般机制。正面。心理。 2039 年 7 月 (2017 年)。
10. Araujo, D., Davids, K. 和 Hristovski, R. 体育决策的生态动力学。心理。体育锻炼。 7(6), 653–676 (2006)。
11. 山本, Y.等人。日本武术中的联合动作语法。PLoS ONE 8(9), 72436 (2013)。
12. Worm, A. 联合战术认知系统：建模、分析和绩效评估。见：人为因素和人体工程学协会年会记录, 卷。 42、315–319。 (SAGE 出版社, 1998 年)。
13. Turvey, M. T. 协同作用层面的行动和感知。哼。移动。科学。 26(4), 657–697 (2007)。
14. Wolpert, D. M. 和 Landy, M. S. 电机控制就是决策。电流。意见。神经生物学。 22(6), 996–1003 (2012)。
15. Goldstone, R. L. & Gureckis, T. M. 集体行为。主题认知。科学。 1(3), 412–438 (2009)。
16. Spivey, M. J. & Dale, R. 实时认知中的连续动态。电流。导演。心理。科学。 15 (5) , 207–211 (2006)。
17. Christensen, W., Sutton, J. 和 McIlwain, D. J. 熟练动作中的认知：网格控制和技能经验的多样性。心朗。 31 (1) , 37–66 (2016)。
18. Christensen, W., Sutton, J. 和 Bicknell, K. 记忆系统和熟练动作的控制。菲洛斯.心理。 32(5), 692–718 (2019)。
19. Martens, J. 一起做事：巧妙的联合行动理论, 卷。 41 (德格鲁特, 2020)。
20. Jacobs, D. M. & Michaels, C. F. 直接学习。生态。心理。 19(4), 321–349 (2007)。
21. van der Kamp, J. & Renshaw, I. 信息-运动耦合作为运动专业知识的标志 50–63 (Routledge, 2015)。
22. 赵 H. 和沃伦 W. H. 动作视觉控制的在线和基于模型的方法。想象。资源。 110, 190–202 (2015)。
23. Simonyan, K. 和 Zisserman, A. 用于大规模图像识别的超深卷积网络 (Springer, 2014 年)。
24. 何K., 张X., 任S., 孙J.图像识别的深度残差学习。IEEE 计算机会议论文集视觉与模式识别, 770–778 (2016)。
25. Deng, L. & Li, X. 语音识别的机器学习范式：概述。IEEE 传输。音频语音语言。过程。 21 (5) , 1060–1089 (2013)。
26. 阿莫代伊, D.等人。深度语音2：英语和普通话的端到端语音识别。国际机器学习会议, 173–182 (2016)。
27. 哈马德, L.等人。用于定量辨别干血滴的机器学习分析。科学。报告 10(1), 1–13 (2020)。
28. 克劳斯, J.等人。分级机变异性以及评估糖尿病视网膜病变机器学习模型的参考标准的重要性。眼科 125(8), 1264–1272 (2018)。



29. 霍尔辛格, A.等人。智能农场和森林运营的数字化转型需要以人为本的人工智能: 挑战和未来方向。传感器 22(8), 3043 (2022)。

30. Cavalcante, I. M.、Frazzon, E. M.、Forcellini, F. A. 和 Ivanov, D. 一种监督机器学习方法, 用于数字制造中弹性供应商选择的数据驱动模拟。国际。J.信息。管理。 49, 86–97 (2019)。

31. 林, W.-Y., 胡, Y.-H. & 蔡, C.-F. 金融危机预测中的机器学习: 一项调查。IEEE 传输。系统人赛博恩。 C 42(4), 421–436 (2011)。

32. Boukerche, A. 和 Wang, J. 用于智能交通系统的基于机器学习的交通预测模型。计算。网络。 181, 107530 (2020)。

33. Tuinhof, H.、Pirker, C. 和 Haltmeier, M. 基于图像的时尚产品推荐与深度学习。机器学习、优化和数据科学国际会议, 472-481 (Springer, 2018)。

34. 帕克, Y.-J. & 张, K.-N. 基于个人和群体行为的客户档案模型, 用于个性化产品推荐。专家系统。应用。 36 (2) , 1932-1939 (2009)。

35. Goodfellow, I.、Bengio, Y. 和 Courville, A. 机器学习基础知识。深度学习。 1, 98–164 (2016)。

36. Langley, P. 机器学习的要素 (Springer, 1996)。

37. Hastie, T.、Tibshirani, R. 和 Friedman, J. 监督学习概述。统计学习的要素, 9-41 (2009)

38. Caruana, R. 和 Niculescu-Mizil, A. 监督学习算法的实证比较。在第 23 届国际会议记录中  
全国机器学习会议, 161–168 (2006)

39. Quinlan, J. R. 决策树归纳。马赫。学习。 1(1), 81–106 (1986)。

40. Safavian, S. R. 和 Landgrebe, D. 决策树分类器方法的调查。IEEE 传输。系统。曼赛博恩。 21 (3) , 660-674 (1991)。

41. Cortes, C. & Vapnik, V. 支持向量网络。马赫。学习。 20(3), 273–297 (1995)。

42. 克里斯蒂安尼尼, N.等人。支持向量机和其他基于内核的学习方法简介 (剑桥大学出版社, 2000 年)。

43. Basheer, I. A. & Hajmeer, M. 人工神经网络: 基础知识、计算、设计和应用。J.微生物学。方法 43(1), 3-31 (2000)。

44. Hochreiter, S. 和 Schmidhuber, J. 长短期记忆。神经计算。 9(8), 1735–1780 (1997)。

45. Hinton, G. E.、Srivastava, N.、Krizhevsky, A.、Sutskever, I. 和 Salakhutdinov, R. R. 通过防止特征检测器的共同适应来改进神经网络 (Springer, 2012 年)。

46. Gers, F. A.、Eck, D. 和 Schmidhuber, J. 将 lstm 应用于通过时间窗口方法可预测的时间序列。神经网络 1, 193–200 (2002)。

47. Chimmula, V.K.R. 和Zhang, L. 使用 LSTM 网络对加拿大 covid-19 传播的时间序列预测。混沌孤子分数。 135, 109864 (2020)。

48. Alhagry, S.、Fahmy, A. A. 和 El-Khoribi, R. A. 使用 LSTM 递归神经网络基于 EEG 的情绪识别。情感 8(10), 355–358 (2017)。

49. Wang, Y., Huang, M., Zhu, X.和Zhao, L.基于Attention的lstm用于aspectlevel情感分类。2016年会议论文集  
自然语言处理经验方法会议, 606–615 (2016)

50. Naretto, F.、Pellungrini, R.、Nardini, F.M. & Giannotti, F. 使用神经网络预测和解释移动数据的隐私风险。见: 欧洲机器学习和数据库知识发现联合会议, 501-516 (2020)。

51. Van Houdt, G.、Mosquera, C. 和 Napoles, G. 对长期短期记忆模型的回顾。阿蒂夫。英特尔。评论 53(8), 5929–5955 (2020)。

52. 阿拉希, A.等人。Social lstm: 拥挤空间中的人类轨迹预测。IEEE 计算机会议论文集  
视觉和模式识别, 961–971 (2016)

53. Tax, N.: 使用 lstm 神经网络预测智能家居环境中的人类活动。见: 2018 年第 14 届智能环境国际会议 (IE) , 40-47 (2018)。

54. Bartoli, F.、Lisanti, G.、Ballan, L. 和 Del Bimbo, A. 上下文感知轨迹预测。见: 2018 年第 24 届国际模式识别会议 (ICPR), 1941–1946 (2018)。

55. Angelini, E.、Di Tollo, G. 和 Roli, A. 信用风险评估的神经网络方法。问: Rev.Econ. 财务。 48(4), 733–755 (2008)。

56. Voigt, P. & Bussche, A. V. D. 欧盟通用数据保护条例 (GDPR): 实用指南第一版。 (施普林格, 2017)。

57. 伦德伯格, S.M.等人。用于预防手术期间低氧血症的可解释的机器学习预测。纳特。生物医学。  
工程师。 2(10), 749–760 (2018)。

58. Parsa, A. B.、Movahedi, A.、Taghipour, H.、Derrible, S. 和 Mohammadian, A.K. 迈向更安全的高速公路, 应用 xgboost 和 shap 进行实时事故检测和特征分析。阿西德。肛门。上一页136, 105405 (2020)。

59. Slack, D.、Hilgard, S.、Jia, E.、Singh, S. 和 Lakkaraju, H. 愚弄石灰和形状: 对事后解释方法的对抗性攻击。  
AAAI/ACM 人工智能、伦理与社会会议记录, 180-186 (2020)。

60. Mokhtari, K.E.、Higdon, B.P. & Başar, A. 用形状值解释金融时间序列。第 29 届计算机科学与软件工程国际会议论文集, 166-172 (2019)。

61. Ribeiro, M.T.、Singh, S. 和 Guestrin, C. “我为什么要相信你?” 解释任何分类器的预测。第 22 届 ACM SIGKDD 国际知识发现和  
数据挖掘会议论文集, 1135–1144 (2016)。

62. Shrikumar, A.、Greenside, P.、Shcherbina, A. 和 Kundaje, A. 不仅仅是一个黑匣子: 通过传播激活差异学习重要特征 (Springer, 2017)。

63. Montavon, G.、Binder, A.、Lapuschkin, S.、Samek, W.、Müller, K.-R.: 逐层相关性传播: 概述。可解释的人工智能: 深度学习的  
解释、解释和可视化, 193-209 (2019)。

64. 阿拉斯, L., 蒙塔文, G., 穆勒, K.-R. & Samek, W. 解释情感分析中的循环神经网络预测。http://arxiv.org/abs/1706.07206 (2017)

65. 伦德伯格, S.M. 和李, S.-I. 解释模型预测的统一方法。副词。神经性的。信息。过程。系统。 30, 4765–4774 (2017)。

66. 伦德伯格, S.M.等人。从局部解释到通过可解释的树木人工智能进行全球理解。纳特。马赫。英特尔。 2(1), 56–67 (2020)。

67. 理查森, M.J. 等人。对嵌入式人际和多主体协调进行建模。第一届复杂信息系统国际会议论文集, 155-164 (2016)。

68. Nalepka, P.、Kallen, R. W.、Chemero, A.、Saltzman, E. 和 Richardson, M. J. 放羊: 紧急多智能体协调和行为模式切换。心理。科  
学。 28 (5) , 630-650 (2017)。

69. 纳莱普卡, P.等人。动态任务环境中人机交互的人类社会运动解决方案。过程。国家。阿卡德。科学。  
116(4), 1437–1446 (2019)。

70. Ma, Y., Yuen, R.K.K. & Lee, E.W.M. 有效领导人群疏散。物理学 A 450, 333–341 (2016)。

71. Rigoli, L.M.等人。采用人类社会运动行为模型作为人工智能训练者。第 19 届自主代理和多代理系统国际会议论文集, 1134–1142 (2020)。

72. 贝奇奥, C.等人。自愿行为的运动学特征。神经心理学 64, 169–175 (2014)。

73. Cavallo, A.、Koul, A.、Ansuini, C.、Capozzi, F. 和 Becchio, C. 从运动运动学解码意图。科学。报告 6(1), 1–8 (2016)。

74. Runeson, S. & Frykholm, G. 动力学的运动学规范作为人和动作感知的信息基础：期望、性别识别和欺骗意图。 J.Exp. 心理。创 112(4), 585 (1983)。

75. McLeod, A. I. Kendall 等级相关性和 Mann-Kendall 趋势检验 (Springer, 2005)。

76. 纳莱普卡, P.等人。任务动态定义了人类圈养行为的情境出现。 PLoS ONE 16(11), 0260046 (2021)。

77. Auletta, F.、Fiore, D.、Richardson, M. J. 和 di Bernardo, M. 通过本地控制规则和在线目标选择策略来引导随机自主代理。奥顿。机 器人。 1, 1–13 (2022)。

78. Welford, W.、Brebner, J. M. 和 Kirby, N. 反应时间 (Springer, 1980)。

79. Auletta, F.、di Bernardo, M. 和 Richardson, M. J. 解决多智能体系统中复杂联合任务的人类启发策略。 IFAC-Pap. 在线 54(17), 105–110 (2021)。

80. Hagaras, H. 迈向人类可理解、可解释的人工智能。计算机 51(9), 28–36 (2018)。

81. Wang, D.、Yang, Q.、Abdul, A. 和 Lim, B. Y. 设计理论驱动的、以用户为中心的可解释人工智能。 2019 年 CHI 计算系统人因会议论 文集, 1-15 (2019)。

82. Alufaisan, Y.、Marusich, L. R.、Bakdash, J. Z.、Zhou, Y. 和 Kantarcioglu, M. 可解释的人工智能是否可以改善人类决策? AAAI 人工智能会议记录, 卷。 35, 6618–6626 (2021)。

83. 莫布斯, D.等人。人类计算行为学的承诺和挑战。神经元 109(14), 2224–2238 (2021)。

84. 普兰茨, M.J. 等人。具有不同信息访问权限的团队搜索行为的结构。认知科学学会年会论文集, 卷。 43 (2021)。

85. Roy, D. 和 Fernando, B. 使用成对的人机交互和变压器进行动作预期。 IEEE 图像处理汇刊。 30, 8116–8129 (2021)。

86. Lim, B.、Arık, S. Ö.、Loeff, N. 和 Pfister, T. 用于可解释的多水平时间序列预测的时间融合变压器。 国际。 J. 预测。 37(4), 1748–1764 (2021)。

87. 萨兰蒂, A.等人。可操作的可解释人工智能 (axai) : 具有用于自适应分类的聚合函数和用于可解释机器学习的文本解释的实际示例。马 赫。学习。知道。提炼。 4(4), 924–953 (2022)。

致谢

作者感谢 Cassandra Crone 的数据编码, 以及 Lilian Rigoli、Gaurav Patil、Patrick Nalepka、Elliot Saltzman、Mark Dras、Erik Reichle、Simon Hosking、Christopher Best、James Simpson 和 Roberto Pellungrini 的协作支持。 Fabrizia Auletta 获得了布里斯托大学的工业和国际杠杆奖以及麦考瑞大学的国际研究卓越奖学金的支持。这项研究还得到了授予 Michael Richardson 的澳大利亚研究委员会未来奖学金 (FT180100447) 和澳大利亚国防部、科学技术小组 (MyIP8655 和 HPRNet ID9024) 的支持。

作者贡献

F.A.、M.B.、R.K.和 M.R. 都参与了研究结果的概念化、制定和评估, 以及手稿的准备。 F.A., M.B.和 M.R. 对数 据建模做出了贡献。 K.R. M.R. 设计并开发了所采用的放牧任务, 并且是收集原始数据的项目的首席研究员。作者 与此处提出的研究没有任何竞争利益。

利益竞争

作者声明没有竞争利益。

附加信息

补充信息 在线版本包含 [https://doi](https://doi.org/10.1038/s41598-023-31807-1) 上提供的补充材料。 org/10.1038/s41598-023-31807-1。

信件和材料请求应发送至 M.B.或 M.J.R.

重印和许可信息可在 [www.nature.com/reprints](http://www.nature.com/reprints) 上获取。

出版商说明施普林格·自然对于已出版地图和机构隶属关系中的管辖权主张保持中立。

开放获取本文根据知识共享署名 4.0 国际许可证获得许可, 该许可证允许以任何媒介或格式使用、共享、改编、 分发和复制, 只要您对原作者和来源给予适当的认可, 提供知识共享许可证的链接, 并指出是否进行了更改。本 文中的图像或其他第三方材料包含在文章的知识共享许可中, 除非材料的信用额度中另有说明。如果文章的知识 共享许可中未包含材料, 并且您的预期用途不受法律法规允许或超出了允许的用途, 您将需要直接获得版权所有 者的许可。要查看此许可证的副本, 请访问 <http://creativecommons.org/licenses/by/4.0/>。